

Algoritmos evolutivos



Inteligencia Artificial en las Organizaciones
Sesión magistral

Del
concepto
a la
aplicación

¿Cómo se representa una
solución?


¿Cómo se evalúa su calidad?

¿Cómo evoluciona una población
hacia mejores soluciones?





¿En qué problemas reales
podemos utilizarlos?

Algoritmos evolutivos

Principales familias y relaciones



Tareas de optimización







Population: 20

Mutation rate: 5%



Genome: 1

Current distance: 249.03

Max distance: 596.81

Max fitness: 66.7

TimeScale: 1X



Generation
20




Generation
88



Generation
999



Casos



Algoritmos genéticos para el reconocimiento facial

Hermosilla G, Gallardo F, Farias G, San Martin C. Fusion of Visible and Thermal Descriptors Using Genetic Algorithms for Face Recognition Systems. Sensors (Basel). 2015;15(8):17944–17962. Published 2015 Jul 23. doi:10.3390/s150817944

Espectro visible vs. espectro térmico

Espectro visible



- ✓ Información de apariencia
- ✓ Amplia utilización en reconocimiento facial



Limitación: sensible a cambios de iluminación

Espectro térmico





- ✓ Información térmica
- ✓ Menor dependencia de la iluminación visible




Limitación: sensible a condiciones ambientales y fisiológicas


Descriptores








¿Dónde entra el algoritmo genético?



¿Qué debe representar un individuo?

The value of the LBP code of a pixel (x_c, y_c) is given by:

$$LBP_{P,R} = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p \quad s(x) = \begin{cases} 1, & \text{if } x \geq 0; \\ 0, & \text{otherwise.} \end{cases}$$




$$1*1 + 1*2 + 1*4 + 1*8 + 0*16 + 0*32 + 0*64 + 0*128 = 15$$

4. Multiply by powers of two and sum

Local binary pattern
(LBP)

Local derivative pattern
(LDP)



Visualización de representaciones
LBP y LDP (en dirección 0).

(a) Imagen original de la cara.

(b) LBP.

(c) LDP de segundo orden.

(d) LDP de tercer orden.

(e) LDP de cuarto orden.




(a)




(b)



(c)




(d)



(e)

Baochang Zhang, Yongsheng Gao, Sanqiang Zhao and Jianzhuang Liu, "Local Derivative Pattern Versus Local Binary Pattern: Face Recognition With High-Order Local Pattern Descriptor," in *IEEE Transactions on Image Processing*, vol. 19, no. 2, pp. 533-544, Feb. 2010.

Base de datos Equinox



Espectro visible

Infrarrojo cercano

Infrarrojo onda media

Infrarrojo onda larga

6 conjuntos galería


9 conjuntos de test

Base de datos PUCV-VTF

Espectro visible




Infrarrojo onda larga



1 conjunto galería

4 conjuntos de test





Requisitos


Funcionamiento en tiempo real

Utilización de sólo una imagen en galería

Alto rendimiento


Esquema del proceso de fusión





LDP (3 orden) – 256 divisiones (8 sectores)

LBP – 32 regiones



LBP – 32 regiones

Cromosoma = 32 pesos visible + 32 pesos térmico

LDP-LBP

LBP-LBP

$$FD^{j,k} = [\omega_{\text{visible}_i} \cdot HI(VD_i^{j,k}) , \omega_{\text{thermal}_i} \cdot HI(TD_i^{j,k})]$$

i : número de regiones de la imagen

FD: descriptor del vector de fusión

VD: descriptor de imagen visible


TD: descriptor de imagen térmica


w_{visible} y w_{thermal} : pesos de la población

HI: función de intersección de histograma

j : imagen de prueba

k : imagen de galería






100 individuos

Cada individuo consta de 64 pesos
aleatorio en el intervalo [0-1]

Pesos complementarios para
regiones para la población inicial



Cada individuo se evalúa sobre la base de datos de descriptores de galería e imágenes de prueba utilizando la ecuación de FD.


$$FD^{j,k} = [\omega_{\text{visible}_i} \cdot HI(VD_i^{j,k}), \omega_{\text{thermal}_i} \cdot HI(TD_i^{j,k})]$$

Se calcula el valor de similaridad


$$SV^{j,k} = \sum_1^{64} FD_i^{j,k}$$

Reconocimiento facial en base a SV

El fitness del individuo es la tasa de reconocimiento




Se seleccionan 2 padres. Método de la ruleta




25% de probabilidad de cruce en cada punto

Se obtienen dos nuevos individuos




25% de probabilidad de mutación en
tres puntos aleatorios



Se calcula el fitness de la nueva población

Se reemplaza un individuo aleatorio de la población si un nuevo individuo tiene mejor fitness




Finaliza al llegar a 100.000
iteraciones

Base de datos Equinox

18.629 para cada espectro
240 X 320 pixeles

Espectro visible

Infrarrojo onda larga



El conjunto galería

81 individuos

Iluminación frontal y lateral

Tres expresiones

Preprocesado

81 X 150 pixeles

Individuos con gafas se almacenan dos veces

Base de datos Equinox

Preprocesado

Todos los sujetos están en cada conjunto

En los conjuntos galería solo hay una imagen por individuo (81)

Los conjuntos de prueba tienen diferente tamaño



15 conjuntos de datos

6 conjuntos galería - 9 conjuntos de test

Conjuntos de test

Sets	Description	Subjects	Illuminations	Image Number
VA	Vowel Frames	All Subjects	All illuminations	729 images
EA	Expressions frames	All Subjects	All illuminations	729 images
VF	Vowel frames	All Subjects	Frontal illumination	243 images
EF	Expressions frames	All Subjects	Frontal illumination	243 images
VL	Vowel frames	All Subjects	Lateral illumination	486 images
EL	Expressions frames	All Subjects	Lateral illumination	486 images
VG	Vowel frames	Subjects Using Glasses	All illuminations	324 images
EG	Expressions frames	Subjects Using Glasses	All illuminations	324 images
RR	Random 500 frames	Chosen at random	All illuminations	500 images

Base de datos PUCV-VTF



PS3Eye Camera

640 X 480 pixeles

FLIR Tau 2
Camera

640 X 512 pixeles

76 individuos

12.160 imágenes en ambos espectros

5 subconjuntos

5 expresiones

Base de datos PUCV-VTF

El grupo “normal” es considerado la galería



Proporcionadas a 81 X 150 pixeles

42 pixeles entre los ojos

Normalizadas

$$I_{norm}(i,j) = \frac{I(i,j) - I_{min}}{I_{max} - I_{min}} (N_{max} - N_{min}) + N_{min} \quad \forall (i,j) \in \Omega$$


Experimentos - Equinox

Entrenamiento:

EA – galería

RR - test


Sets	Description	Subjects	Illuminations	Image Number
VA	Vowel Frames	All Subjects	All illuminations	729 images
EA	Expressions frames	All Subjects	All illuminations	729 images
VF	Vowel frames	All Subjects	Frontal illumination	243 images
EF	Expressions frames	All Subjects	Frontal illumination	243 images
VL	Vowel frames	All Subjects	Lateral illumination	486 images
EL	Expressions frames	All Subjects	Lateral illumination	486 images
VG	Vowel frames	Subjects Using Glasses	All illuminations	324 images
EG	Expressions frames	Subjects Using Glasses	All illuminations	324 images
RR	Random 500 frames	Chosen at random	All illuminations	500 images



Experimentos - Equinox

Method	Visible (%)	Thermal (%)
LBP_HI_80	81.60	93.89
LBP_HI_32	80.11	95.32
LDP2_X2_32	83.12	88.98
LDP3_HI_256	88.20	61.10
LDP3_X2_32	85.22	73.30
HOG_X2_256	73.59	94.03
WLD_HI_80	78.89	84.86
WLD_X2_80	38.05	85.19
GJD	85.35	70.07
FD-LDP-LBP	96.99	
FD-LBP-LBP	95.64	
Wavelets [18]	93.50	
PCA [18]	92.90	
KPCA [19]	82.70	
KFLD [19]	96.30	
Wavelets [20]	96.10	

AVERAGE RECOGNITION RATES FOR EQUINOX DATABASE





Áreas representativas en cada espectro

Se utilizó la **mejor población** del experimento anterior

Se utiliza el criterio “top” para la tasa de reconocimiento

Variant	Visible (%)	Thermal (%)
LBP_HI_80	91.45	98.68
LBP_X2_32	96.71	98.03
LDP2_HI_32	94.08	91.78
LDP2_HI_256	91.12	93.09
LDP3_X2_32	78.95	83.22
LDP3_EU_256	74.01	86.51
HOG_EU_256	93.09	97.04
HOG_X2_256	92.76	97.70
WLD_HI_80	90.46	97.70
GJD	80.26	92.76
FD-LDP-LBP		98.68
FD-LBP-LBP		99.01

Se utilizó la **mejor población** del experimento anterior

Se utiliza el criterio “top” para la tasa de reconocimiento

Variant	Average Recognition Rate-Test Sets				Average
	Frown	Glasses	Smile	Vowels	
LBP_X2_32 (Visible)	96.05	96.05	98.68	96.05	96.71
LBP_HI_80 (Thermal)	96.05	98.68	100.00	100.00	98.68
LDP2_HI_32 (Visible)	94.74	93.42	94.74	93.42	94.08
LDP2_HI_256 (Thermal)	89.47	92.11	97.37	93.42	93.09
LDP3_X2_32 (Visible)	65.79	77.63	86.84	85.53	78.95
LDP3_EU_256 (Thermal)	82.89	78.95	98.68	85.53	86.51
HOG_EU_256 (Visible)	88.16	92.11	96.05	96.05	93.09
HOG_X2_256 (Thermal)	96.05	97.37	98.68	98.68	93.09
WLD_HI_80 (Visible)	85.53	85.53	97.37	93.42	90.46
WLD_HI_80 (Thermal)	96.05	97.37	100.00	97.37	97.70
GJD (Visible)	60.53	69.74	97.37	93.42	80.26
GJD (Thermal)	92.11	82.89	100.00	96.05	92.76
FD-LDP-LBP	98.68	97.37	100.00	98.68	98.68
FD-LBP-LBP	98.68	98.68	100.00	98.68	99.01

De los algoritmos genéticos a la visión multimodal actual

2015 • Caso estudiado

Reconocimiento facial visible + térmico mediante fusión optimizada con AG



Imagen visible (RGB)



Imagen térmica (IR)

LBP

(32 regiones)

LDP

(32 regiones)



Algoritmo genético

Optimiza los pesos de fusión
(64 genes: 32 + 32)

2026 • Visión multimodal

Modelos profundos para integrar múltiples modalidades de forma conjunta



Visible (RGB)



Térmico (IR)



Profundidad (Depth)



Texto (Metadatos)

...

Modelos profundos

CNN • Vision Transformers
Modelos visión-lenguaje (VLM)



Optimización en visión multimodal

- Aprendizaje end-to-end de la fusión
- Búsqueda de arquitecturas e hiperparámetros
- Ajuste de funciones de pérdida
- Optimización con datos limitados o restricciones



¿Qué papel tienen hoy los algoritmos evolutivos?



Sí, siguen siendo relevantes

Como herramienta de optimización complementaria en visión y aprendizaje automático.



Diseño y ajuste de modelos

Búsqueda de arquitecturas, selección de características y optimización de hiperparámetros.



Problemas no diferenciables o con restricciones

Funciones de evaluación complejas, múltiples objetivos, restricciones de diseño o eficiencia.



Nuevos escenarios

Optimización en modelos generativos y multimodales, búsqueda eficiente en espacios muy grandes y con datos limitados.



La forma de construir el sistema ha cambiado;
el problema de optimización permanece.



Idea clave

Los algoritmos evolutivos no sustituyen al modelo de visión, pero siguen siendo útiles para buscar buenas soluciones en espacios complejos, especialmente cuando la optimización no es fácilmente diferenciable.



Generación de pose sentado usando algoritmo genético

M. Al-Hami and R. Lakaemper, "Sitting pose generation using genetic algorithm for NAO humanoid robots," 2014 IEEE International Workshop on Advanced Robotics and its Social Impacts, Evanston, IL, 2014, pp. 137-142.



Incremento del uso de humanoides para imitar al ser humano








OBJETIVO

Encontrar una postura óptima para sentarse basada en el estado físico que satisfaga los parámetros del objeto en que se puede sentar



Robot NAO



Características 25 grados de libertad

Capacidades limitadas a:

- Detección de colisión
- Estimación de distancia
- Motor físico



Robot NAO

Se utilizan tres distancias:

entre cabeza y suelo

entre caderas y superficie del objeto

entre caderas y superficie del suelo

$$\mathcal{F} : \mathcal{S} \rightarrow \mathcal{L} \in \mathcal{U}$$

$\mathcal{F}$

función de fitness

$\mathcal{S}$

todas las poses posibles para sentarse

$\mathcal{L}$


valor de fitness

$\mathcal{U}$


seis niveles monotónicamente crecientes

$$p' = \operatorname{argmax}_{p \in \mathcal{S}} \mathcal{F}(p)$$







(a) Initial Pose




(b) Zero Pose



(c) Intermediate Pose




(d) Intermediate Pose




(e) Initial Sitting Pose




(f) Initial Pose




(g) Zero Pose



(h) Intermediate Pose



(i) Intermediate Pose



(j) Initial Sitting Pose

Descubriendo la altura del objeto donde se puede sentar


Metas

- Detectar colisiones
- Las caderas del robot deben colocarse sobre el objeto


Se utiliza una ruta de movimiento estable predefinida

El proceso ajusta articulaciones específicas

- LkneePitch, RkneePitch, LHipPitch, RHipPitch



Proceso de búsqueda de la posición óptima de sentado



Bloques de articulaciones utilizados



BLOCK	Used Joints	Number of Joints
Left Arm	LShoulderRoll, LShoulderPitch, LElbowYaw, LWristYaw, LElbowRoll	5
Right Arm	RShoulderRoll, RShoulderPitch, RElbowYaw, RWristYaw, RElbowRoll	5
Left Leg	LHipYawPitch, LHipPitch, LKneePitch, LAnklePitch, LAnkleRoll, LHipRoll	6
Right Leg	RHipYawPitch, RHipPitch, RKneePitch, RAnklePitch, RAnkleRoll, RHipRoll	6

Algoritmo Genético


Algorithm 1 Evolutionary GA Approach for Optimal Sitting Pose Generation

```
1:  $t \leftarrow 1$  {Generation counter}
2:  $\mathcal{G}_t \leftarrow \mathcal{I}$ 
3: repeat
4:   for all  $p \in \mathcal{G}_t$  do
5:     Compute  $\mathcal{F}(p)$  fitness
6:   end for
7:   Elitist  $\leftarrow$  From  $\mathcal{G}_t$  Select  $E\%$  of highest  $\mathcal{F}(p) \quad \forall p \in \mathcal{G}_t$  { $E$  is the elitist strategy percent}
8:    $\mathcal{C} \leftarrow 1$  {Poses counter in each generation}
9:   Population  $\leftarrow []$ 
10:  while  $\mathcal{C} \leq$  Samples Size do
11:    Parents  $\leftarrow$  tournament selection
12:    if (rand < CrossRate) then
13:      Chromosome  $\leftarrow$  Crossover(Parents) {Crossover at block level}
14:    end if
15:    if (rand < MutRate) then
16:      Chromosome  $\leftarrow$  Mutation(Chromosome)
17:    end if
18:    Population  $\leftarrow$  Population + Chromosome
19:     $\mathcal{C} \leftarrow \mathcal{C} + 1$ 
20:  end while
21:   $t \leftarrow t + 1$ 
22:   $\mathcal{G}_t \leftarrow$  Elitist + Select from Population using residual sub sampling
23: until (Generations limit or optimal pose  $\hat{p}$  is reached)
```


	Right Arm					Left Arm					Right Leg						Left Leg					
<i>Parent₁</i>	-28	58	84	0	89	28	58	-86	0	-89	-1	-100	0	4	0	0	-1	-100	0	4	0	0
<i>Parent₂</i>	-51	18	84	101	42	44	-2	-82	-101	-38	-38	-67	82	9	-9	13	-38	-80	87	9	-13	20
Crossover	-28	58	84	0	89	44	-2	-82	-101	-38	-1	-100	0	4	0	0	-1	-100	0	4	0	0
Mutation	0	0	0	+3	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
Child	-28	58	84	+3	89	44	-2	-82	-101	-38	-1	-100	0	4	0	0	-1	-100	0	4	0	0

Generación de un nuevo descendiente


CrossRate = 0,9
MutRate = 0,6
La mutación es a lo sumo de 5 grados




(a) Cube Box 12 cm height



(b) Cube Box 15 cm height



(c) Ball 05 cm radius



(d) Ball 7.5 cm radius



(e) Cube 12 cm height



(f) Cube 15 cm height



(g) Ball 05 cm radius



(h) Ball 7.5 cm radius



NAO: optimización robótica en la era generativa




Ayer

AG aplicados al control de posturas (NAO: generación de poses estables).
Optimización de movimientos con restricciones físicas.



Hoy

IAG genera escenarios sintéticos de interacción y simulaciones realistas.
Deep Learning en visión y percepción del entorno.



Todavía vigente

Algoritmos evolutivos siguen siendo esenciales para optimización motora en robots.
Complementariedad: IAG imagina / simula, IA clásica optimiza y controla.
NAO es ejemplo didáctico de cómo las organizaciones deben integrar enfoques híbridos.



Algoritmos evolutivos



Inteligencia Artificial en las Organizaciones
Sesión magistral