

Redes de Neuronas Artificiales

Inteligencia Artificial en las Organizaciones
Sesión magistral

Revisión de conceptos

¿Qué es una RNA?

¿Neurona, axón, sinapsis?

¿Cómo funcionan los pesos en una RNA?

¿Cuáles son las arquitecturas de RNA más comunes?


¿Cuáles son algunos de los parámetros de diseño para desarrollar una red neuronal?

¿Cómo se implementan las redes neuronales en la práctica cuando el entrenamiento / prueba está completo?

¿Qué es el llamado síndrome de "caja negra"?

¿Qué son los conjuntos de clasificadores?

State-of-the-art in artificial neural network applications: A survey




Evolución de las Redes Neuronales: del perceptrón a la IA generativa

Una misma familia de modelos, con creciente complejidad, representaciones y aplicaciones

Perceptrón


(modelo lineal)



- Modelo lineal simple
- Aprende ajustando sus pesos a partir de datos
- Limitado a problemas linealmente separables

Perceptrón multicapa (MLP)


(red feedforward)



- Múltiples capas ocultas
- Aprende representaciones no lineales
- Base de muchas aplicaciones actuales
- Es una red neuronal, pero no necesariamente profunda

Deep Learning

(redes neuronales profundas)



- Muchas capas de representación
- Gran capacidad para aprender patrones complejos
- Requiere grandes volúmenes de datos y mayor capacidad de cómputo
- Incluye arquitecturas como CNN, RNN y Transformers

Arquitecturas especializadas


(según el tipo de dato y problema)



CNN

(visión por computador)


- Imágenes, video
- Detección, segmentación



RNN / LSTM

(datos secuenciales)

- Series temporales, texto
- Dependencias temporales



Transformers

(lenguaje, multimodal)

- Texto, imagen, audio, ...)
- Mecanismo de atención
- Escalabilidad

IA generativa

(modelos de gran escala)



Modelos de lenguaje

- ChatGPT, Gemini, Claude, ...
- Generación y comprensión de texto



Generación de imágenes

- DALL·E, Stable Diffusion, ...
- Imágenes y vídeo



Generación de audio

- Whisper, MusicGen, ...
- Voz, música, ...



Modelos multimodales

- Texto + imagen + audio + ...)
- Aplicaciones en múltiples dominios

Los modelos actuales de IA generativa son una evolución de las redes neuronales,
no una tecnología independiente.

The Neural Network Zoo

A mostly complete chart of Neural Networks


©2019 Fjodor van Veen & Stefan Leijnen asimovinstitute.org

-  Input Cell
-  Backfed Input Cell
-  Noisy Input Cell
-  Hidden Cell
-  Probabilistic Hidden Cell
-  Spiking Hidden Cell
-  Capsule Cell
-  Output Cell
-  Match Input Output Cell
-  Recurrent Cell
-  Memory Cell
-  Gated Memory Cell
-  Kernel
-  Convolution or Pool


Perceptron (P)




Feed Forward (FF)




Radial Basis Network (RBF)




Deep Feed Forward (DFF)




Recurrent Neural Network (RNN)




Long / Short Term Memory (LSTM)




Gated Recurrent Unit (GRU)




Auto Encoder (AE)




Variational AE (VAE)




Denosing AE (DAE)




Sparse AE (SAE)




Markov Chain (MC)




Hopfield Network (HN)




Boltzmann Machine (BM)




Restricted BM (RBM)




Deep Belief Network (DBN)




Deep Convolutional Network (DCN)




Deconvolutional Network (DN)




Deep Convolutional Inverse Graphics Network (DCIGN)



Generative Adversarial Network (GAN)




Liquid State Machine (LSM)




Extreme Learning Machine (ELM)




Echo State Network (ESN)




Deep Residual Network (DRN)




Differentiable Neural Computer (DNC)




Neural Turing Machine (NTM)




Capsule Network (CN)



Kohonen Network (KN)



Attention Network (AN)



Fuente: <http://www.asimovinstitute.org/neural-network-zoo/>



Caso



Red de Neuronas para advertencia de colisión por alcance

Donghoun Lee and Hwasoo Yeo. 2016. Real-Time Rear-End Collision-Warning System Using a Multilayer Perceptron Neural Network. Trans. Intell. Transport. Sys. 17, 11 (November 2016), 3087-3097. DOI: <https://doi.org/10.1109/TITS.2016.2537878>

Uno de los tipos más comunes de accidentes de tránsito en autopistas es la **colisión trasera**






50GL44 000KM/H 2016/05/05 14:26:25

Juicio erróneo del conductor:


Percepción inexacta

Subestimación de frenado requerido

Tiempo de reacción necesario



- EXTERIOR CAMERA
- INTERIOR CAMERA
- LIDAR
- SHORT/ MEDIUM RANGE RADAR
- LONG-RANGE RADAR



SISTEMAS AVANZADOS DE AYUDA A LA CONDUCCIÓN (ADAS)












Sistema de advertencia de colisión trasera



Comunicación V2I



Comunicación V2V



Perception-Reaction Time **PRT**

Sistemas de alerta de colisión trasera

Algoritmos basados en enfoques paramétricos

Poca adaptación al PRT

Pueden ser molestos

Pueden no advertir

Sistema de alarma de colisión en tiempo real sin influencia del PRT basado en el perceptrón multicapa en un entorno V2I



Algoritmos de
Sistemas de
Advertencia
de Colisión
Trasera
(RE-CWS)

Enfoque perceptivo

Enfoque cinemático

Enfoque basado en RNA

Enfoque perceptivo



$$TTC = \frac{h - L}{V_F - V_P}$$

h = space headway


L = longitud del vehículo delantero

V = velocidades

Existen variaciones del TTC

Algoritmo Honda

Enfoque cinemático



*Todas las variables son observables
en un entorno V2I, excepto PRT*



Algoritmo Stopping Distance

Algoritmo Berkeley

Algoritmo Mazda

Metodología

Arquitectura del perceptrón multicapa





¿Cómo se determina la clase?


Identificación de riesgos basada en desaceleración crítica

Distribución de frecuencia acumulativa de casos de frenado



Perfil crítico de desaceleración





60%

de las colisiones traseras se pueden evitar con una advertencia 0,5 segundos antes.



90%


de las colisiones traseras con un segundo extra de anticipación.

Resultados de estudios previos (citados por los autores)




1,5 s

Tiempo mínimo de advertencia
adoptado en el estudio para permitir una maniobra evasiva.



Operación MCWA en entorno de comunicación V2I.

Entrenamiento y predicción en tiempo real mediante periodos rodantes



Procesamiento en cada periodo RP_n

Modelo de RP_{n-1}
(pesos entrenados con datos anteriores)

Predice el riesgo en RP_n
(nivel de advertencia)

Mientras tanto...

Llegan datos de RP_n
(Gap, V_F , V_P , a_F , a_P)

Se entrenan / actualizan los pesos del MLP
(con los datos de RP_n)

Modelo para RP_{n+1}

Mientras se predice el presente, se aprende para el siguiente periodo.

Datos

Segmento de 640m

Seguimiento de vehículos individuales

5 carriles

Frecuencia de 0.1 segundo

Desde las 7:50 a las 8:35

El 15 de junio de 2005

U.S. Department of Transportation
Federal Highway Administration

TRAFFIC ANALYSIS TOOLS PROGRAM

OFFICE OF OPERATIONS 21ST CENTURY OPERATIONS USING 21ST CENTURY TECHNOLOGIES

Search
Traffic Analysis Tools:
 Go

[Home](#)
[Tools](#)
[FAQs](#)
[Links](#)
[Contact Us](#)

Development Resources

[Next-Generation Simulation \(NGSIM\)](#)
[Dynamic Traffic Assignment \(Dynamart-P\)](#)

Guidance Resources

[Corridor Simulation \(CORSIM/TSIS\)](#)
[Training & Workshops](#)

Next Generation Simulation (NGSIM)

Traffic Analysis Tools

Goal

To develop a core of open behavioral algorithms in support of traffic simulation with a primary focus on microsimulation documentation and validation data sets that describe the interactions of multimodal travelers, vehicles and highways from traffic control devices, delineation, congestion, and other features of the environment.

Objectives

1. To ensure that NGSIM research meets the needs of stakeholders, addresses existing gaps, and that its products are available to the simulation community.
2. To collect data sets for the research, development, and validation of behavioral algorithms and for use by other researchers.
3. To develop new behavioral algorithms and improve existing algorithms in order to incorporate previously unavailable data and improve the trustworthiness of existing models.

The NGSIM data sets, algorithms, and reports are freely available for download at the U.S. DOT Intelligent Transportation Systems (ITS) Data Center [here](#).

Additional Resources



U.S. Route 101

Datos

Datos microscópicos derivados de cada trayectoria

- Localización
- Aceleración
- Espacio entre morros
- Carril ocupado
- Información del vehículo precedente y siguiente


Hay ruido en los datos

Se aplica un filtro – Filtro de media móvil (1s)

Se asume que corresponden a tráfico real



Datos



Tasa de aceleración

Carril específico

Primeros 15 minutos

Datos



Se excluyen camiones y motocicletas
(462)

322 casos de seguimiento de automóviles
durante el segundo periodo


53 de 322 presentan al menos un
“frenado brusco”.



Análisis de sensibilidad



Análisis de sensibilidad



Tiempo computacional por periodo rodante para los 53 casos de seguimiento de vehículos.

Estudio comparativo

Se compara el sistema con los algoritmos Honda y Berkeley


La capacidad de advertir se compara cada 0.1 segundo




Se utiliza uno de los casos extremos de los 322 casos

Se configura para que adviertan 1.5 segundos antes de la colisión


Estudio comparativo

Algoritmo Honda







Algoritmo Berkeley



Sistema Propuesto - MCWA




Evaluación - ROC



		Actual Class	
		Positive	Negative
Prediction	Positive	True Positive (TP)	False Positive (FP)
	Negative	False Negative (FN)	True Negative (TN)


$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{FP + TN}$$




Variable	Area
<i>Honda</i>	0.636
<i>Berkeley</i> ($\tau = 0.5$)	0.683
<i>Berkeley</i> ($\tau = 1.5$)	0.710
<i>Berkeley</i> ($\tau = 2.5$)	0.704
<i>MCWA</i>	0.810

Área bajo la curva ROC



$$\text{Precision} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Positive}}$$

$$= \frac{\text{True Positive}}{\text{Total Predicted Positive}}$$



$$\text{Recall} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Negative}}$$

$$= \frac{\text{True Positive}}{\text{Total Actual Positive}}$$


Curvas precisión-recall

Ideas clave

De los fundamentos de las redes neuronales a la IA generativa

1 Aprender

Las redes neuronales aprenden **patrones ajustando sus pesos** a partir de datos.



2 Elegir

La arquitectura depende del problema y de los datos. Más complejidad no implica mejores resultados.



3 Escalar

Los mismos fundamentos han evolucionado hacia **Deep Learning, Transformers e IA generativa**.



Mismos fundamentos. Mayor escala. Nuevas capacidades.



Red de Neuronas para advertencia de colisión por alcance

Donghoun Lee and Hwasoo Yeo. 2016. Real-Time Rear-End Collision-Warning System Using a Multilayer Perceptron Neural Network. Trans. Intell. Transport. Sys. 17, 11 (November 2016), 3087-3097. DOI: <https://doi.org/10.1109/TITS.2016.2537878>